

RAC 首测配置与房间分配

DiscoveryBench + CORE-Bench
三个 host · N0 / R1 / R3 · 配置快照 2026-09-22

18

计划实验数

12

已配置独立房间

USD 40

每次 agent 费用上限

当前状态：任务输入、六份实验配置、三份队列清单及 12 组房间凭据已准备。自动队列执行器尚未实现；模型、judge 和 SharedNet 真实接口尚未验证。本文是首测计划与配置记录，不是实验结果报告。

01 测试目标与规模

目标是验证三个原生科研 host 在两类 benchmark 上的运行、提交、独立评分、错误处理和调试日志流程。每个 benchmark 选择一个任务，seed = 0，每个条件运行一次；R2 本轮不单独测试。单任务首测不能代表整个 benchmark 的效果。

02 两个已选任务

项目	DiscoveryBench	CORE-Bench
任务 ID	nls_bmi/metadata_0/0/0	capsule-4180912
分区 / 协议	原始 train real-no-domain-knowledge	本地 dev，来自固定 HAL test hal-hard-cpu
任务内容	分析 1989 年数据中与较高 BMI 相关的时间偏好因素。	运行 clasificador.py 和 clasificador_dt.py，回答神经网络准确率、随机森林 macro F1 两项数值问题。
准备依据	公开问题、数据和原始列说明已准备，输入 hash 已检查。	Python / CPU；压缩包 56,216 字节；公开代码已静态检查，尚未实测耗时。

03 三个对照条件

条件	本轮含义	房间
N0	完整原生 host 生命周期；使用原生调度。	不需要
R1	原生固定后继，加 SharedNet 运行时通信。	每项独立
R3	包含通信、运行时路由、工作契约及 advisory verifier。	每项独立

CORE 的 dev 是本地开发分区，选中 capsule 后不得再次纳入后续 eval。所有条件使用相同 task / seed / 生命周期预算，并保持同一任务的输入与环境协议一致。

全部 18 项实验与房间对应

每个 host 的本地顺序均为：Discovery N0 → R1 → R3，然后 CORE N0 → R1 → R3。以下编号用于阅读；正式 episode_id 以队列 JSON 为准。

序号	Host	Benchmark	条件	槽位	Room ID	凭据状态
01	ARK	Discovery	N0	-	不使用 SharedNet	不适用
02	ARK	Discovery	R1	01	rom_7GSuAYIJbR	格式通过
03	ARK	Discovery	R3	02	rom_ylmwf01Dp4	格式通过
04	ARK	CORE	N0	-	不使用 SharedNet	不适用
05	ARK	CORE	R1	03	rom_LTWacMg8H	格式通过
06	ARK	CORE	R3	04	rom_6K4Pft6eZp	格式通过
07	Agent Laboratory	Discovery	N0	-	不使用 SharedNet	不适用
08	Agent Laboratory	Discovery	R1	05	rom_crZ7zkY0IR	格式通过
09	Agent Laboratory	Discovery	R3	06	rom_rnZm1GFFrM	格式通过
10	Agent Laboratory	CORE	N0	-	不使用 SharedNet	不适用
11	Agent Laboratory	CORE	R1	07	rom_gNUy1VVT4J	格式通过
12	Agent Laboratory	CORE	R3	08	rom_YHOLi16Xm8	格式通过
13	EvoScientist	Discovery	N0	-	不使用 SharedNet	不适用
14	EvoScientist	Discovery	R1	09	rom_YBBGxNEzkk	格式通过
15	EvoScientist	Discovery	R3	10	rom_E3wj d7mUMo	格式通过
16	EvoScientist	CORE	N0	-	不使用 SharedNet	不适用
17	EvoScientist	CORE	R1	11	rom_a5tjsodrtg	格式通过
18	EvoScientist	CORE	R3	12	rom_gSDCLVLrc0	格式通过

12 个 Room ID 和 invite token 均互不重复、格式合法。仅进行了本地格式检查，没有连接 SharedNet、加入房间或发送消息。房间实际可加入性尚未验证。

槽位 01 使用原来已填入 .env、用户确认未用过的房间；槽位 02–12 按用户提供的顺序分配。槽位 08 已使用用户补发的完整 token。一个 episode 内的多个 agent 角色共享该房间；不同 episode 不复用，启动过的 episode 若需重试应换新房间。

凭据存放：secrets/sharednet/smoke/<槽位>-<benchmark>-<host>-<条件>.env。PDF 仅含 Room ID，不含 invite token、成员凭据或模型 API key。

预算、模型与评分协议

Host	费用	输入 token	输出 token	调用次数	最长时间	hops
ARK	USD 40	100,000,000	1,800,000	1,500	12 小时	23
Agent Laboratory	USD 40	60,000,000	1,300,000	900	6 小时	8
EvoScientist	USD 40	60,000,000	1,300,000	900	6 小时	8

预算按单个 episode 的完整生命周期累计；输出 token 上限不是单次请求的输出长度。三种条件在同一 host 下使用同一组预算。18 次 agent 配置预算合计 USD 720，不是预计花费，且不包含 Discovery 的独立 judge 费用。

预算来源

ARK 的 token / 调用 / 时长沿用交接手册 \$5.2 的旧 Math_000 N0 Pro 队列上限；另外两个 host 暂借用 \$4.2 通用示例，未核实为各自的历史实际值。费用 USD 40 和 hops (23 / 8 / 8) 按用户当前要求覆盖。尚未针对这两个任务校准预算。

模型与凭据

用途	配置	验证状态
被评估模型	DeepSeek-V4-Pro AGENT_API_BASE / AGENT_API_KEY	配置与密钥已填；本机真实模型调用未验收。
Discovery judge	Azure / gpt-5.4 API version: 2025-04-01-preview	JUDGE_API_BASE / JUDGE_API_KEY 已填；兼容性 & 真实评分待验收。
CORE 评分	固定 HAL 官方数值评分逻辑	本任务不调用外部 LLM judge。

提交与分数

Benchmark	提交文件与校验	评分规则
Discovery	discovery_result.json hypothesis 与 workflow 必须是非空字符串。	独立 scorer 使用私有参考及官方 judge 流程；主分数为 final_score。
CORE	report.json 键必须逐字匹配任务中的两个问题，值为数值答案。	沿用官方预测区间等规则；task accuracy 要求全部问题正确。

评分失败、无效提交分别记录为 scorer_failed / invalid_submission, total_score = null；不得伪装成有效 0 分。Discovery 现有适配调用 max_tokens / temperature，尚需核对部署兼容性；根 .env 的 JUDGE_MAX_COMPLETION_TOKENS=1000 属旧 RCB 参数，当前 Discovery 适配器并未读取它。

本机环境与配置文件

环境记录来自 2026-09-22 已有离线验收报告，本次没有重新启动或探测容器。运行平台为当前 Windows 电脑的 WSL2 Ubuntu 24.04 与 Docker Engine。

Host	Python	已准备的主要组件	状态
ARK	3.12.14	OpenHands、PaperBanana、Conda、LaTeX / Pandoc / tmux	已有离线验收通过
Agent Laboratory	3.11.16	PyTorch CPU、TensorFlow CPU、离线 MiniLM、完整原生流程导入	已有离线验收通过
EvoScientist	3.13.15	EvoScientist、deepagents、LangChain、QuickJS、原生 shell	已有离线验收通过

CORE 的独立任务运行环境

使用固定 bootstrap-python-cpu 镜像，每个 episode 创建全新运行环境，配置 4 CPU / 8 GB 内存。安装 capsule 依赖计入该 episode；controller 管理 Docker，host 通过 runtime URL 和 token 访问，同一 workspace 必须以相同绝对路径挂载。

已有独立 runtime 离线验收：基础包清单、文件共享、超时杀进程、禁止跨 episode 复用及清理。根 .env 的 RAC_TASK_RUNTIME_URL / TOKEN 仍为空，需由尚未完成的执行器按 episode 创建及注入。

配置与数据索引

用途	仓库内路径 / 说明
三个队列清单	configs/queues/ark.smoke.json configs/queues/agent_laboratory.smoke.json configs/queues/evo_scientist.smoke.json
六份实验配置	configs/discoverybench.<host>.json configs/corebench.<host>.json
房间配置	secrets/sharednet/smoke/*.env room-slots.json 记录槽位、房间和格式检查状态。
Discovery 输入	prepared_tasks/discoverybench/train/nls_bmi/metadata_0/0/0/
CORE 输入	prepared_tasks/corebench/dev/capsule-4180912/
CORE 私有参考	upstreams/benchmark-data/corebench/core_test.json 只供 controller / scorer 使用，不提供给 host。
模型与 judge 凭据	根目录 .env；本报告不输出任何 key 或 token。

host 可见输入不含 Discovery 标准假设、workflow 参考或 CORE 官方结果、环境定义与运行脚本。secrets、prepared_tasks 和本地 upstream 数据均由 Git 忽略规则覆盖。

执行策略、日志与验收状态

当前三份清单标记为 queue_plan_only。下列自动评分、跳错和日志行为是执行器必须实现的要求；尚无自动执行器读取这些清单，不能据此宣称队列已跑通。

计划的逐项处理流程

读取固定配置与 prepared 输入 → 创建独立 workspace / runtime → 执行当前 host 与条件 → 停止并清理 agent/runtime → 尝试独立评分 → 记录状态和全部调试输出 → 前进到下一项。运行错误或评分错误均保留记录并继续；无提交时明确标记无法评分；不自动重试、不覆盖旧记录。

每项实验要求保留的日志

文件 / 数据	用途
controller.jsonl	阶段转换、开始结束时间、退出码、错误分类、配置与镜像身份。
host.stdout.log / host.stderr.log	host 原始标准输出和错误输出；落盘前清除凭据。
scorer.stdout.log / scorer.stderr.log	完整评分进程输出；与 host 隔离，可能包含私有参考内容。
task-runtime/	每次命令、超时、环境初始化、文件操作和容器清理记录。
episode.json / score.json / workspace	最终实验状态、评分状态、分数、合法提交和产物；保存路径按执行器实现冻结。

队列清单已为每项预留 runs/queue-logs/smoke/<episode_id>/。当前没有本轮真实输出日志或分数；已有 runs/environment-check/ 仅为环境验收记录。

验收边界与剩余工作

项目	当前状态
任务与计划	2 项 prepared 输入、6 份配置、3 个队列、18 个 episode；本地静态检查通过。
SharedNet	12 组凭据已填，格式合法且无重复；尚未联网验收。
主机环境	已有 CPU 环境及独立 runtime 离线验收通过；不等于真实科研任务跑通。
自动执行器	待实现并验证：自动运行与评分、异常继续、清理、日志和凭据脱敏。
真实验收与结果	DeepSeek / Discovery judge 接口待验证；尚未执行 N0 / R1 / R3，本轮无结果。

可复现来源

配置与房间映射以 configs/queues/、configs/<benchmark>.<host>.json 和本地 room-slots.json 为准。环境证据：runs/environment-check/validated-2026-09-22.json；预算来源与限制：docs/queue-budget-settings.zh-CN.md；任务准备协议：docs/benchmark-adapters.zh-CN.md。

固定上游：Discovery c31fcf011e070f021a5f5b906896d0821f6880e8
HAL / CORE 16bb03ebc11577fb5ea6dc8bb6c968387085e6aa
完整 scorer hash 与版本记录见 benchmark.lock.json；各 episode 的配置与输入 hash 已写入队列清单。